



Un investigador recopiló datos sobre tres variables psicológicas, cuatro variables académicas (resultados de exámenes estandarizados) y de género para 600 estudiantes de primer año de universidad.

Está interesado en la forma en que el conjunto de variables psicológicas se relaciona con las variables académicas y el sexo.

En particular, el investigador está interesado en saber cuántas dimensiones (variables canónicas) son necesarias para comprender la asociación entre los dos conjuntos de variables.

Las variables psicológicas son

- capacidad de control
- autoconcepto
- motivación

y las académicas son las pruebas estandarizadas de

- lectura (READ)
- escritura (WRITING)
- matemáticas (MATH)
- y ciencia (SCIENCE)

# Planteo del problema



## Definiciones



## Estimación





## Criterio de Wilks



## CCA regularizada



## CCA rala



Sea  $\mathbf{z} = (z_1, \dots, z_{p+q})^T = \begin{pmatrix} \mathbf{x} \\ \mathbf{y} \end{pmatrix} \in \mathbb{R}^d$  donde  $d = p + q$ ,  $\mathbf{x} \in \mathbb{R}^p$ ,  $\mathbf{y} \in \mathbb{R}^q$ . Supongamos por simplicidad que  $\mathbb{E}\mathbf{z} = \mathbf{0}_d$ . Sea

$$\text{Cov}(\mathbf{z}) = \boldsymbol{\Sigma} = \begin{pmatrix} \boldsymbol{\Sigma}_{11} & \boldsymbol{\Sigma}_{12} \\ \boldsymbol{\Sigma}_{21} & \boldsymbol{\Sigma}_{22} \end{pmatrix}$$

donde  $\boldsymbol{\Sigma}_{11} \in \mathbb{R}^{p \times p}$ ,  $\boldsymbol{\Sigma}_{22} \in \mathbb{R}^{q \times q}$ . Supongamos  $\boldsymbol{\Sigma} > 0$ .

**Supongamos  $p = 1$**

Queremos medir la relación lineal entre  $z_1$  y  $\mathbf{y} = (z_2, \dots, z_d)^T \Rightarrow$  usamos el cuadrado del coeficiente de correlación múltiple,  $\rho_{1,(23\dots d)}^2$  que es *la máxima correlación al cuadrado entre  $z_1$  y cualquier combinación lineal  $\boldsymbol{\beta}^T \mathbf{y}$*

$$\rho_{1,(23\dots d)}^2 = \frac{\sigma_{21}^T \boldsymbol{\Sigma}_{22}^{-1} \sigma_{21}}{\sigma_{11}}$$

donde  $\sigma_{21} = \text{Cov}(\mathbf{y}, z_1)$  y el máximo se alcanzaba en  $\boldsymbol{\beta}_0 = \boldsymbol{\Sigma}_{22}^{-1} \sigma_{21}$ .

## Caso General: $q < p$

Queremos medir la asociación entre  $\mathbf{x}$  y  $\mathbf{y}$  que estará dada por:

*la máxima correlación al cuadrado entre cualquier combinación lineal  $\alpha^T \mathbf{x}$  y cualquier combinación lineal  $\beta^T \mathbf{y}$*

$$\max_{\alpha \neq \mathbf{0}_p, \beta \neq \mathbf{0}_q} \rho_{\alpha, \beta}^2$$

con

$$\rho_{\alpha, \beta}^2 = \frac{\text{COV}^2(\alpha^T \mathbf{x}, \beta^T \mathbf{y})}{\text{VAR}(\alpha^T \mathbf{x}) \text{VAR}(\beta^T \mathbf{y})} = \frac{(\alpha^T \Sigma_{12} \beta)^2}{\alpha^T \Sigma_{11} \alpha \beta^T \Sigma_{22} \beta}$$

Sea  $\Sigma_{jj} = \mathbf{A}_j^T \mathbf{A}_j$ ,

$$\Psi_1 = (\mathbf{A}_1^T)^{-1} \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21} \mathbf{A}_1^{-1} \quad \Psi_2 = (\mathbf{A}_2^T)^{-1} \Sigma_{21} \Sigma_{11}^{-1} \Sigma_{12} \mathbf{A}_2^{-1}$$

entonces

$$\max_{\alpha \neq \mathbf{0}_p, \beta \neq \mathbf{0}_q} \rho_{\alpha, \beta}^2 = \rho_{\alpha_1, \beta_1}^2 = \rho_1^2$$

- $\rho_1^2$  es el máximo autovalor de  $\Psi_1$ , es decir, el máximo autovalor de  $\Sigma_{11}^{-1} \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}$
- $\alpha_1$  es el autovector de  $\Sigma_{11}^{-1} \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}$  asociado a  $\rho_1^2$  tal que  $\alpha_1^T \Sigma_{11} \alpha_1 = 1$ .
- $\beta_1$  es el autovector de  $\Sigma_{22}^{-1} \Sigma_{21} \Sigma_{11}^{-1} \Sigma_{12}$  asociado a  $\rho_1^2$  tal que  $\beta_1^T \Sigma_{22} \beta_1 = 1$ .

$$\beta_1 = \frac{\Sigma_{22}^{-1} \Sigma_{21} \alpha_1}{\rho_1} \quad \alpha_1 = \frac{\Sigma_{11}^{-1} \Sigma_{12} \beta_1}{\rho_1}$$

## Definición.

- $\rho_1 = \sqrt{\rho_1^2}$  se llama la **primer correlación canónica** entre  $\mathbf{x}$  y  $\mathbf{y}$ .
- $u_1 = \alpha_1^T \mathbf{x}$ ,  $v_1 = \beta_1^T \mathbf{y}$  se llaman las **primeras variables canónicas**. Se cumple  $\text{VAR}(u_1) = \text{VAR}(v_1) = 1$

Como  $\mathbf{\Sigma}_{12} \mathbf{\Sigma}_{22}^{-1} \mathbf{\Sigma}_{21} \alpha_1 = \rho_1^2 \mathbf{\Sigma}_{11} \alpha_1$  y  $\alpha_1^T \mathbf{\Sigma}_{11} \alpha_1 = 1$  tenemos que

$$\rho_1^2 = \alpha_1^T \mathbf{\Sigma}_{12} \mathbf{\Sigma}_{22}^{-1} \mathbf{\Sigma}_{21} \alpha_1$$

O sea,  $\rho_1^2$  es el cuadrado del coeficiente de correlación multiple entre la variable  $u_1 = \alpha_1^T \mathbf{x}$  y el vector  $\mathbf{y}$  ya que  $\text{VAR}(u_1) = 1$  y  $\text{COV}(u_1, \mathbf{y}) = \mathbf{\Sigma}_{21} \alpha_1$ .



## Cómo seguimos?

Este procedimiento puede verse como una técnica de reducción de dimensión en la que  $\mathbf{x}$  y  $\mathbf{y}$  se reducen a  $u_1$  y  $v_1$  de modo que  $\rho_{\alpha, \beta}^2$  sea máxima. Pero, la reducción  $u_1$  de  $\mathbf{x}$  puede no ser adecuada.

Buscamos  $\mathbf{u} = (u_1, \dots, u_m)^T$  y  $\mathbf{v} = (v_1, \dots, v_m)$  tales que

- $u_j = \alpha_j^T \mathbf{x}$ ,  $v_j = \beta_j^T \mathbf{y}$
- $u_1, \dots, u_m$  sean no correlacionados
- $v_1, \dots, v_m$  sean no correlacionados
- $\text{CORR}(u_j, v_j)$  sea máxima en algún sentido

Observemos primero que como hablamos de correlaciones podemos suponer que  $\text{VAR}(u_j) = \text{VAR}(v_j) = 1$ , es decir,

$$\alpha_j^T \Sigma_{11} \alpha_j = 1 \quad \beta_j^T \Sigma_{22} \beta_j = 1$$

## Teorema

Supongamos  $\Sigma_{11} > 0$ ,  $\Sigma_{22} > 0$ ,  $q < p$ ,  $\Sigma_{jj} = \mathbf{A}_j^T \mathbf{A}_j$ . Sean

- $\mathbf{C} = (\mathbf{A}_1^T)^{-1} \Sigma_{12} \mathbf{A}_2^{-1}$
- $\Upsilon_1 = \Sigma_{11}^{-1} \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}$
- $\Upsilon_2 = \Sigma_{22}^{-1} \Sigma_{21} \Sigma_{11}^{-1} \Sigma_{12}$
- $1 > \rho_1^2 \geq \rho_2^2 \geq \dots \geq \rho_m^2 > 0$  con  $m = \text{rango}(\Sigma_{12})$  los autovalores no nulos de  $\Upsilon_1$  (y de  $\Upsilon_2$ )
- $\alpha_1, \dots, \alpha_m$  los autovectores de  $\Upsilon_1$  asociados a  $\rho_1^2 \geq \rho_2^2 \geq \dots \geq \rho_m^2$  tales que  $\alpha_j^T \Sigma_{11} \alpha_j = 1$
- $\beta_1, \dots, \beta_m$  los autovectores de  $\Upsilon_2$  asociados a  $\rho_1^2 \geq \rho_2^2 \geq \dots \geq \rho_m^2$  tales que  $\beta_j^T \Sigma_{22} \beta_j = 1$

Sea  $s \leq m - 1$  y sean  $\alpha \in \mathbb{R}^p$  y  $\beta \in \mathbb{R}^q$  tales que

$$\text{Cov}(\alpha^T \mathbf{x}, \alpha_j^T \mathbf{x}) = 0 \quad 1 \leq j \leq s$$

$$\text{Cov}(\beta^T \mathbf{y}, \beta_j^T \mathbf{y}) = 0 \quad 1 \leq j \leq s$$



- i) La máxima correlación al cuadrado entre  $\alpha^T \mathbf{x}$  y  $\beta^T \mathbf{y}$  está dada por  $\rho_{s+1}^2$  y ocurre cuando  $\alpha = \alpha_{s+1}$  y  $\beta = \beta_{s+1}$ , o sea,

$$\max_{\alpha \neq 0, \beta \neq 0} \rho_{\alpha, \beta}^2 = \rho_{s+1}^2 = \rho_{\alpha_{s+1}, \beta_{s+1}}^2$$

$$\text{Cov}(\alpha^T \mathbf{x}, \alpha_j^T \mathbf{x}) = 0, 1 \leq j \leq s$$

$$\text{Cov}(\beta^T \mathbf{y}, \beta_j^T \mathbf{y}) = 0, 1 \leq j \leq s$$

ii)  $\text{COV}(\alpha_j^T \mathbf{x}, \alpha_k^T \mathbf{x}) = 0$  si  $j \neq k$  y  $\text{COV}(\beta_j^T \mathbf{y}, \beta_k^T \mathbf{y}) = 0$  si  $j \neq k$

iii)  $\text{VAR}(\alpha_j^T \mathbf{x}) = \text{VAR}(\beta_j^T \mathbf{y}) = 1$

iv) Sea  $m = \text{rango}(\mathbf{\Sigma}_{12}) \leq \min(q, p) = q$  y tomemos

$$\mathbf{u} = \mathbf{A}^T \mathbf{x} \text{ con } \mathbf{A} = (\alpha_1, \dots, \alpha_m, \alpha_{m+1}, \dots, \alpha_p)$$

$$\mathbf{v} = \mathbf{B}^T \mathbf{y} \text{ con } \mathbf{B} = (\beta_1, \dots, \beta_q)$$

Luego, si  $\mathbf{D}_\rho = \text{DIAG}(\rho_1, \dots, \rho_q)$  con  $\rho_i = 0$  si  $i > m$

$$\text{VAR} \begin{pmatrix} \mathbf{u} \\ \mathbf{v} \end{pmatrix} = \begin{pmatrix} \mathbf{I}_q & \mathbf{0} & \mathbf{D}_\rho \\ \mathbf{0} & \mathbf{I}_{p-q} & \mathbf{0} \\ \mathbf{D}_\rho & \mathbf{0} & \mathbf{I}_q \end{pmatrix}$$

o sea,  $\text{Cov}(u_i, v_j) = 0$  si  $i \neq j$  y  $\text{Cov}(u_i, v_i) = \rho_i$

## Definición.

- $\mathbf{u}$  se llama las variables canónicas del espacio  $\mathbf{x}$ .
- $\mathbf{v}$  se llama las variables canónicas del espacio  $\mathbf{y}$ .
- $\alpha_1, \dots, \alpha_m$  y  $\beta_1, \dots, \beta_m$  son los vectores canónicos
- $u_j$  es la  $j$ -ésima variable canónica en el espacio  $\mathbf{x}$
- $v_j$  es la  $j$ -ésima variable canónica en el espacio  $\mathbf{y}$

La relación entre  $\mathbf{x}$  y  $\mathbf{y}$  queda expresada por las correlaciones canónicas  $\rho_1^2, \dots, \rho_m^2$

Como  $\Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}\alpha_j = \rho_j^2\Sigma_{11}\alpha_j$  y  $\alpha_j^T\Sigma_{11}\alpha_j = 1$  tenemos que

$$\rho_j^2 = \alpha_j^T \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21} \alpha_j$$

O sea,  $\rho_j^2$  es el cuadrado del coeficiente de correlación multiple entre la variable  $u_j = \alpha_j^T \mathbf{x}$  y el vector  $\mathbf{y}$ , pues  $\text{VAR}(u_j) = 1$  y  $\text{COV}(u_j, \mathbf{y}) = \Sigma_{21}\alpha_j$ .

## Otro enfoque

$$\Sigma_{jj} = \mathbf{A}_j^T \mathbf{A}_j \quad \mathbf{A}_j > 0 \quad \mathbf{C} = (\mathbf{A}_1^T)^{-1} \Sigma_{12} \mathbf{A}_2^{-1}$$

Por la descomposición de valores singulares

$$\mathbf{C} = \mathbf{L} \begin{pmatrix} \mathbf{D}_\rho \\ \mathbf{0}_{(p-q) \times q} \end{pmatrix} \mathbf{M}^T$$

- $\mathbf{L} = (\ell_1, \dots, \ell_p) \in \mathbb{R}^{p \times p}$ ,  $\mathbf{M} = (\mathbf{m}_1, \dots, \mathbf{m}_q) \in \mathbb{R}^{q \times q}$ ,  
ortogonales,  $\mathbf{m}_j \in \mathbb{R}^q$  y  $\ell_j \in \mathbb{R}^p$ .
- $\mathbf{D}_\rho = \text{DIAG}(\rho_1, \dots, \rho_q)$ ,  $\rho_1 \geq \rho_2 \geq \dots \geq \rho_q \geq 0$ ,  
 $\rho_j$  es la raíz cuadrada de  $j$ -ésimo autovalor de  $\mathbf{C}^T \mathbf{C} = \Psi_2$ .

Los vectores  $\{\mathbf{m}_1, \dots, \mathbf{m}_q\}$  son los autovectores de  $\mathbf{C}^T \mathbf{C} = \Psi_2$  y

$$\ell_j = \frac{\mathbf{C} \mathbf{m}_j}{\rho_j} \quad 1 \leq j \leq q$$

son los autovectores ortonormales de  $\mathbf{C} \mathbf{C}^T = \Psi_1$

Definamos

$$\begin{aligned}\mathbf{u} &= \mathbf{L}^T (\mathbf{A}_1^{-1})^T \mathbf{x} = (u_1, \dots, u_p)^T & u_j &= (\mathbf{A}_1^{-1} \ell_j)^T \mathbf{x} \\ \mathbf{v} &= \mathbf{M}^T (\mathbf{A}_2^{-1})^T \mathbf{y} = (v_1, \dots, v_q)^T & v_j &= (\mathbf{A}_2^{-1} \mathbf{m}_j)^T \mathbf{y}\end{aligned}$$

Entonces,

$$\text{VAR} \begin{pmatrix} \mathbf{u} \\ \mathbf{v} \end{pmatrix} = \begin{pmatrix} \mathbf{I}_p & \begin{pmatrix} \mathbf{D}_\rho \\ \mathbf{0} \end{pmatrix} \\ (\mathbf{D}_\rho & \mathbf{0}) & \mathbf{I}_q \end{pmatrix}$$

- $\text{VAR}(u_i) = \text{VAR}(u_j) = 1$
- $\text{CORR}(u_i, v_j) = \rho_i \delta_{ij}, 1 \leq i \leq p, 1 \leq j \leq q.$

**Definición.** Las variables  $u_1, \dots, u_p$  y  $v_1, \dots, v_q$  se llaman las **variables canónicas** y los números  $\rho_j, \rho_1 \geq \rho_2 \geq \dots \geq \rho_q \geq 0$  son las **correlaciones canónicas**.

La cantidad de correlaciones no nulas es  $m = \text{rango}(\mathbf{\Sigma}_{12})$

**Las dos definiciones coinciden**

Sean dos puntos  $\mathbf{x}_1 \in \mathbb{R}^p$ ,  $\mathbf{x}_2 \in \mathbb{R}^p$  y definamos

$$\mathbf{u}_i = \mathbf{L}^T (\mathbf{A}_1^{-1})^T \mathbf{x}_i = (u_{1,i}, \dots, u_{p,i})^T \quad u_{j,i} = (\mathbf{A}_1^{-1} \ell_j)^T \mathbf{x}_i \quad i = 1, 2$$

Luego,

$$\|\mathbf{u}_1 - \mathbf{u}_2\|^2 = \|\mathbf{L}^T (\mathbf{A}_1^{-1})^T (\mathbf{x}_1 - \mathbf{x}_2)\|^2 = (\mathbf{x}_1 - \mathbf{x}_2)^T \boldsymbol{\Sigma}_{11}^{-1} (\mathbf{x}_1 - \mathbf{x}_2)$$

Sean dos puntos  $\mathbf{y}_1 \in \mathbb{R}^p$ ,  $\mathbf{y}_2 \in \mathbb{R}^p$  y definamos

$$\mathbf{v}_i = \mathbf{M}^T (\mathbf{A}_2^{-1})^T \mathbf{y}_i = (v_{1,i}, \dots, v_{q,i})^T \quad v_{j,i} = (\mathbf{A}_2^{-1} \mathbf{m}_j)^T \mathbf{y}_i \quad i = 1, 2$$

Luego,

$$\|\mathbf{v}_1 - \mathbf{v}_2\|^2 = \|\mathbf{M}^T (\mathbf{A}_2^{-1})^T (\mathbf{y}_1 - \mathbf{y}_2)\|^2 = (\mathbf{y}_1 - \mathbf{y}_2)^T \boldsymbol{\Sigma}_{22}^{-1} (\mathbf{y}_1 - \mathbf{y}_2)$$

O sea, distancias entre puntos del espacio de las variables canónicas representan distancias de Mahalanobis en el espacio original.

Al usar, la reducción de  $s$  variables canónicas, las distancias entre puntos del espacio de variables canónicas dan aproximadamente la distancia de Mahalanobis en el espacio original.



## Resumen de propiedades de las variables y correlaciones canónicas

- Las variables canónicas son indicadores de los dos conjuntos de variables que se definen por pares, con la condición de máxima correlación
- Los coeficientes de las variables canónicas son los autovectores asociados al mismo autovalor de las matrices

$$\Sigma_{ii}^{-1} \Sigma_{ij} \Sigma_{jj}^{-1} \Sigma_{ji} \quad i = 1, 2 \quad i \neq j$$

- Si  $\alpha_j^T \mathbf{x}$  es una variable canónica también lo es  $-\alpha_j^T \mathbf{x}$ . Los signos de las variables canónicas suelen tomarse para que la correlación entre las variables canónicas  $u_j = \alpha_j^T \mathbf{x}$  y  $v_j = \beta_j^T \mathbf{y}$  sean positiva.
- Los cuadrados de las correlaciones canónicas  $\rho_j^2$  son los autovalores de  $\mathbf{\Upsilon}_1 = \Sigma_{11}^{-1} \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21}$  y  $\mathbf{\Upsilon}_2 = \Sigma_{22}^{-1} \Sigma_{21} \Sigma_{11}^{-1} \Sigma_{12}$ , o sea las raíces de

$$|\Sigma_{11}^{-1} \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21} - \lambda \mathbf{I}_p| = 0$$

## Resumen de propiedades de las variables y correlaciones canónicas

- Los cuadrados de las correlaciones canónicas  $\rho_j^2$  son el cuadrado del coeficiente de correlación entre las dos variables canónicas  $u_j = \alpha_j^T \mathbf{x}$  y  $v_j = \beta_j^T \mathbf{y}$  correspondientes.
- Las correlaciones canónicas son invariantes ante transformaciones lineales no singulares de las variables.
- La primer correlación canónica  $\rho_1^2$  es mayor o igual que el mayor coeficiente de correlación al cuadrado entre una variable de cada conjunto.

$$\rho_1^2 \geq \text{CORR}^2(x_i, y_j) \quad \text{para todo} \quad 1 \leq i \leq p, 1 \leq j \leq q$$

- El coeficiente de correlación canónica  $\rho_j^2$  es el cuadrado del coeficiente de correlación múltiple entre la variable  $u_j = \alpha_j^T \mathbf{x}$  y el vector  $\mathbf{y}$ .
- El coeficiente de correlación canónica  $\rho_j^2$  es el cuadrado del coeficiente de correlación múltiple entre la variable  $v_j = \beta_j^T \mathbf{y}$  y el vector  $\mathbf{x}$ .

## Resumen de propiedades de las variables y correlaciones canónicas

- Las variables canónicas son predictores óptimos en el siguiente sentido:

Queremos hallar  $2s$  combinaciones lineales  $\mathbf{u} = \mathbf{A}_s^T \mathbf{x}$  y  $\mathbf{v} = \mathbf{B}_s^T \mathbf{y}$  con  $s \leq m = \text{rango}(\boldsymbol{\Sigma}_{12})$

- $\mathbf{A}_s = (\mathbf{a}_1, \dots, \mathbf{a}_s)$ ,  $\mathbf{a}_1, \dots, \mathbf{a}_s$  linealmente independientes (o sea,  $\text{rango}(\mathbf{A}_s) = s$ )
- $\mathbf{B}_s = (\mathbf{b}_1, \dots, \mathbf{b}_s)$ ,  $\mathbf{b}_1, \dots, \mathbf{b}_s$  linealmente independientes (o sea,  $\text{rango}(\mathbf{B}_s) = s$ )
- $\mathbf{A}_s^T \boldsymbol{\Sigma}_{11} \mathbf{A}_s = \mathbf{I}_s$ ,  $\mathbf{B}_s^T \boldsymbol{\Sigma}_{22} \mathbf{B}_s = \mathbf{I}_s$

tales que  $\mathbb{E} \|\mathbf{u} - \mathbf{v}\|^2$  sea mínima.

El mínimo se alcanza si  $\mathbf{a}_j = \boldsymbol{\alpha}_j$  y  $\mathbf{b}_j = \boldsymbol{\beta}_j$ .

## Propiedades

**Propiedad 1.** Sean

$$\mathbf{\Delta}_x = \text{DIAG}(\text{VAR}(x_1), \dots, \text{VAR}(x_p))$$

$$\mathbf{\Delta}_y = \text{DIAG}(\text{VAR}(y_1), \dots, \text{VAR}(y_q))$$

Se tiene que

- $\text{CORR}(u_j, x_\ell) = \mathbb{E}(x_\ell \mathbf{x}^T) \boldsymbol{\alpha}_j / \sqrt{\text{VAR}(x_\ell)}$
- $\text{CORR}(v_j, y_\ell) = \mathbb{E}(y_\ell \mathbf{y}^T) \boldsymbol{\beta}_j / \sqrt{\text{VAR}(y_\ell)}$

es decir,

$$\text{CORR}(u_j, \mathbf{x}) = \mathbf{\Delta}_x^{-\frac{1}{2}} \boldsymbol{\Sigma}_{11} \boldsymbol{\alpha}_j$$

$$\text{CORR}(v_j, \mathbf{y}) = \mathbf{\Delta}_y^{-\frac{1}{2}} \boldsymbol{\Sigma}_{22} \boldsymbol{\beta}_j$$

$$\text{CORR}(u_j, \mathbf{y}) = \mathbf{\Delta}_y^{-\frac{1}{2}} \boldsymbol{\Sigma}_{21} \boldsymbol{\alpha}_j$$

$$\text{CORR}(v_j, \mathbf{x}) = \mathbf{\Delta}_x^{-\frac{1}{2}} \boldsymbol{\Sigma}_{12} \boldsymbol{\beta}_j$$

**Propiedad 2.** Si  $\mathbf{z} \sim N(\mathbf{0}, \boldsymbol{\Sigma})$ ,  $\mathbf{x}$  es independiente de  $\mathbf{y}$  si y sólo si  $\rho_1 = 0$ .

## Propiedades

### Propiedad 3. Invarianza del análisis.

Si llamamos  $\mathbf{z}^* = \begin{pmatrix} \Delta_{\mathbf{x}}^{-\frac{1}{2}} \mathbf{x} \\ \Delta_{\mathbf{y}}^{-\frac{1}{2}} \mathbf{y} \end{pmatrix}$  y efectuamos el análisis de correlación canónica de  $\mathbf{z}^*$ , o sea, en lugar de

$$\mathbf{\Upsilon}_1 = \Sigma_{11}^{-1} \Sigma_{12} \Sigma_{22}^{-1} \Sigma_{21} \quad \mathbf{\Upsilon}_2 = \Sigma_{22}^{-1} \Sigma_{21} \Sigma_{11}^{-1} \Sigma_{12}$$

tomamos

$$\mathbf{\Upsilon}_1^* = \mathbf{R}_{11}^{-1} \mathbf{R}_{12} \mathbf{R}_{22}^{-1} \mathbf{R}_{21} \quad \mathbf{\Upsilon}_2^* = \mathbf{R}_{22}^{-1} \mathbf{R}_{21} \mathbf{R}_{11}^{-1} \mathbf{R}_{12}$$

con  $\mathbf{R}_{ij}$  las matrices de correlación entonces

- Las correlaciones canónicas no cambian
- $\alpha_j^* = \Delta_{\mathbf{x}}^{1/2} \alpha_j$ ,
- $\beta_j^* = \Delta_{\mathbf{y}}^{1/2} \beta_j$

Por lo tanto, las variables canónicas  $u_j$  y  $v_j$  son las mismas.

Sean  $\mathbf{z}_i = \begin{pmatrix} \mathbf{x}_i \\ \mathbf{y}_i \end{pmatrix} \in \mathbb{R}^d$  i.i.d. con densidad  $(\Sigma > 0)$ ,  $\mathbf{x}_i \in \mathbb{R}^p$ ,  $\mathbf{y}_i \in \mathbb{R}^q$ . Sea

- $\tilde{\mathbf{x}}_i = \mathbf{x}_i - \bar{\mathbf{x}}$
- $\tilde{\mathbf{y}}_i = \mathbf{y}_i - \bar{\mathbf{y}}$
- $\tilde{\mathbf{X}} = \begin{pmatrix} \tilde{\mathbf{x}}_1^T \\ \vdots \\ \tilde{\mathbf{x}}_n^T \end{pmatrix} \quad \tilde{\mathbf{Y}} = \begin{pmatrix} \tilde{\mathbf{y}}_1^T \\ \vdots \\ \tilde{\mathbf{y}}_n^T \end{pmatrix}$
- $\mathbf{Q}_{11} = \tilde{\mathbf{X}}^T \tilde{\mathbf{X}}, \mathbf{Q}_{22} = \tilde{\mathbf{Y}}^T \tilde{\mathbf{Y}}, \mathbf{Q}_{12} = \tilde{\mathbf{X}}^T \tilde{\mathbf{Y}}.$
- $\mathbf{S}_{ij} = \mathbf{Q}_{ij} / (n - 1)$
- $\mathbf{S} = \begin{pmatrix} \mathbf{S}_{11} & \mathbf{S}_{12} \\ \mathbf{S}_{21} & \mathbf{S}_{22} \end{pmatrix}$

Supongamos  $n > d = p + q$  y  $q < p$  luego  $\mathbf{S}$  es definida positiva con probabilidad 1 y  $\text{rango}(\mathbf{Q}_{12}) = q$ .

**Definición.** Se definen las **correlaciones canónicas muestrales**  $r_j$ ,  $r_1 > r_2 > \dots > r_q > 0$  (con prob. 1) como  $r_j = \sqrt{r_j^2}$  donde  $r_1^2 > r_2^2 > \dots > r_q^2 > 0$  (con prob. 1) son los autovalores de

$$\hat{\mathbf{T}}_1 = \mathbf{S}_{11}^{-1} \mathbf{S}_{12} \mathbf{S}_{22}^{-1} \mathbf{S}_{21} \quad \text{o de} \quad \hat{\mathbf{T}}_2 = \mathbf{S}_{22}^{-1} \mathbf{S}_{21} \mathbf{S}_{11}^{-1} \mathbf{S}_{12}$$

o sea, la solución de

$$|\mathbf{S}_{11}^{-1} \mathbf{S}_{12} \mathbf{S}_{22}^{-1} \mathbf{S}_{21} - \lambda \mathbf{I}_p| = 0 \quad \text{o} \quad |\mathbf{S}_{12} \mathbf{S}_{22}^{-1} \mathbf{S}_{21} - \lambda \mathbf{S}_{11}| = 0$$

**Definición.** Se definen las **variables canónicas muestrales** como

- $\mathbf{u}_i = (u_{1,i}, \dots, u_{q,i})^T$  con  $u_{j,i} = \hat{\boldsymbol{\alpha}}_j^T \tilde{\mathbf{x}}_i$  y
- $\mathbf{v}_i = (v_{1,i}, \dots, v_{q,i})^T$   $v_{j,i} = \hat{\boldsymbol{\beta}}_j^T \tilde{\mathbf{y}}_i$

$$\begin{aligned} \mathbf{S}_{11}^{-1} \mathbf{S}_{12} \mathbf{S}_{22}^{-1} \mathbf{S}_{21} \hat{\boldsymbol{\alpha}}_j &= r_j^2 \hat{\boldsymbol{\alpha}}_j & \hat{\boldsymbol{\alpha}}_j^T \mathbf{S}_{11} \hat{\boldsymbol{\alpha}}_j &= 1 \\ \mathbf{S}_{22}^{-1} \mathbf{S}_{21} \mathbf{S}_{11}^{-1} \mathbf{S}_{12} \hat{\boldsymbol{\beta}}_j &= r_j^2 \hat{\boldsymbol{\beta}}_j & \hat{\boldsymbol{\beta}}_j^T \mathbf{S}_{22} \hat{\boldsymbol{\beta}}_j &= 1 \end{aligned}$$

Observemos que

$$\begin{aligned} 1 &= \hat{\boldsymbol{\alpha}}_j^T \mathbf{S}_{11} \hat{\boldsymbol{\alpha}}_j = \frac{1}{n-1} \sum_{i=1}^n u_{j,i}^2 \\ 1 &= \hat{\boldsymbol{\beta}}_j^T \mathbf{S}_{22} \hat{\boldsymbol{\beta}}_j = \frac{1}{n-1} \sum_{i=1}^n v_{j,i}^2 \end{aligned}$$

La distribución exacta de  $r_j$ , aún en el caso  $\mathbf{z}_i \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$  es complicada (ver Muirhead, 1982, sección 11.3.4). La distribución asintótica puede verse en Bilodeau & Brenner (1999, sección 11.5).



## Distribución asintótica de $r_j^2$

**Proposición 1.** Sean  $\mathbf{z}_i \sim N(\boldsymbol{\mu}, \boldsymbol{\Sigma})$  i.i.d., tales que  $\rho_1 > \rho_2 > \dots > \rho_k > \rho_{k+1} = \dots = \rho_p = 0$ , luego

$$\sqrt{n} (r_j^2 - \rho_j^2) \xrightarrow{D} N\left(0, 4 \rho_j^2 (1 - \rho_j^2)^2\right), \quad j = 1, \dots, k$$

- Más aún, si  $\mathbf{r}_k^{(2)} = (r_1^2, \dots, r_k^2)^T$  y  $\boldsymbol{\rho}_k^{(2)} = (\rho_1^2, \dots, \rho_k^2)$  entonces

$$\sqrt{n} (\mathbf{r}_k^{(2)} - \boldsymbol{\rho}_k^{(2)}) \xrightarrow{D} N\left(\mathbf{0}_q, 4 \text{DIAG}\left(\rho_1^2 (1 - \rho_1^2)^2, \dots, \rho_k^2 (1 - \rho_k^2)^2\right)\right)$$

- Además,  $\mathbf{r}_k^{(2)}$  es independiente de  $r_j$  para  $j > k$ .

## Distribución asintótica de $r_j^2$

- Si  $w_j = nr_j^2$  para  $j > k$ , entonces  $w_{k+1}, \dots, w_q$  son dependientes y no-normales.
- La distribución asintótica conjunta de  $\mathbf{w} = (w_{k+1}, \dots, w_q)^T$  es la distribución de los autovalores de una matriz  $\mathbf{A} \in \mathbb{R}^{(q-k) \times (q-k)}$  tal que  $\mathbf{A} \sim \mathcal{W}(\mathbf{I}_{q-k}, q - m, p - k)$ .
- La densidad asintótica de  $\mathbf{w}$  es

$$C \exp\left\{-\frac{1}{2} \sum_{j=k+1}^q w_j\right\} \prod_{j=k+1}^q w_j^{\frac{p-q-1}{2}} \prod_{k+1 \leq i < j \leq q} (w_i - w_j)$$

## Ejemplo

La matriz **S** es igual a

	<i>Control</i>	<i>Concept</i>	<i>Motiv.</i>	<i>Read</i>	<i>Write</i>	<i>Math</i>	<i>Science</i>	<i>Sex</i>
<i>Control</i>	0.449	0.081	0.056	2.530	2.340	2.128	2.112	0.038
<i>Concept</i>	0.081	0.498	0.070	0.432	0.133	0.356	0.478	-0.044
<i>Motiv.</i>	0.056	0.070	0.117	0.729	0.848	0.629	0.385	0.017
<i>Read</i>	2.530	0.432	0.729	102.070	61.769	64.611	67.730	-0.210
<i>Write</i>	2.340	0.133	0.848	61.769	94.604	57.935	53.732	1.184
<i>Math</i>	2.128	0.356	0.629	64.611	57.935	88.637	59.354	-0.226
<i>Science</i>	2.112	0.478	0.385	67.730	53.732	59.354	94.210	-0.668
<i>Sex</i>	0.038	-0.044	0.017	-0.210	1.184	-0.226	-0.668	0.248

Las correlaciones canónicas son

$j$	1	2	3
$r_j$	0.464	0.167	0.104

En CANCOR, los vectores canónicos están normalizados de modo que

$$\hat{\alpha}_j^T \mathbf{Q}_{11} \hat{\alpha}_j = 1 \quad \hat{\beta}_j^T \mathbf{Q}_{22} \hat{\beta}_j = 1$$

mientras que en CCA, están normalizados de modo que

$$\hat{\alpha}_j^T \mathbf{S}_{11} \hat{\alpha}_j = 1 \quad \hat{\beta}_j^T \mathbf{S}_{22} \hat{\beta}_j = 1$$

Estos últimos son los que presentamos

	$\hat{\alpha}_1$	$\hat{\alpha}_2$	$\hat{\alpha}_3$
Control	-1.2538	-0.6215	-0.6617
Concept	0.3513	-1.1877	0.8267
Motivation	-1.2624	2.0273	2.0002
	$\hat{\beta}_1$	$\hat{\beta}_2$	$\hat{\beta}_3$
Read	-0.0446	-0.0049	0.0214
Write	-0.0359	0.0421	0.0913
Math	-0.0234	0.0042	0.0094
Science	-0.0050	-0.0852	-0.1098
Sex	-0.6321	1.0846	-1.7946

Los coeficientes canónicos se interpretan en forma análoga a los coeficientes de regresión, o sea, por ejemplo para la variable *Read* una unidad de incremento en Lectura lleva a un 0.0446 de decrecimiento en la primer variable canónica  $\mathbf{v}_1$  cuando todas las demás variables permanecen constantes.

Planteo del problema  
○○○  
○

Definiciones  
○○○○○○○  
○○○○○○○○○

Estimación  
○○○○○  
○○●○○○○○○○

Criterio de Wilks  
○○  
○○○○

Inferencia  
○○○○○  
○○○○  
○○○○○○○

CCA regularizada  
○○○○○  
○○  
○○○○○○○

CCA rala  
○○○





Por otra parte

	$\text{CORR}(\mathbf{u}_1, \mathbf{x})$	$\text{CORR}(\mathbf{u}_2, \mathbf{x})$	$\text{CORR}(\mathbf{u}_3, \mathbf{x})$	$\text{CORR}(\mathbf{v}_1, \mathbf{x})$	$\text{CORR}(\mathbf{v}_2, \mathbf{x})$	$\text{CORR}(\mathbf{v}_3, \mathbf{x})$
<i>Control</i>	-0.9040	-0.3897	-0.1756	-0.4196	-0.0653	-0.0183
<i>Concept</i>	-0.0208	-0.7087	0.7052	-0.0097	-0.1187	0.0733
<i>Motivation</i>	-0.5672	0.3509	0.7451	-0.2632	0.0588	0.0775


	$\text{CORR}(\mathbf{u}_1, \mathbf{y})$	$\text{CORR}(\mathbf{u}_2, \mathbf{y})$	$\text{CORR}(\mathbf{u}_3, \mathbf{y})$	$\text{CORR}(\mathbf{v}_1, \mathbf{y})$	$\text{CORR}(\mathbf{v}_2, \mathbf{y})$	$\text{CORR}(\mathbf{v}_3, \mathbf{y})$
<i>Read</i>	-0.3900	-0.0601	0.0141	-0.8404	-0.3588	0.1354
<i>Write</i>	-0.4068	0.0109	0.0265	-0.8765	0.0648	0.2546
<i>Math</i>	-0.3545	-0.0499	0.0154	-0.7639	-0.2979	0.1478
<i>Science</i>	-0.3056	-0.1134	-0.0240	-0.6584	-0.6768	-0.2304
<i>Sex</i>	-0.1690	0.1265	-0.0565	-0.3641	0.7549	-0.5434



○○○




b)




- Porqué el gráfico en b) es una nube de puntos sin estructura?
- En a) cada punto es la correlación de la variable indicada con los ejes  $u_1$ ,  $u_2$ .
- En b), las distancias entre puntos del espacio de variables canónicas  $(u_{1,i}, u_{2,i}) = (\hat{\alpha}_1^T \tilde{\mathbf{x}}_i, \hat{\alpha}_2^T \tilde{\mathbf{x}}_i)$  dan aproximadamente la distancia de Mahalanobis entre observaciones  $\tilde{\mathbf{x}}_i$ .



a)



b)



- En a) cada punto es la correlación de la variable indicada con los ejes  $v_1$ ,  $v_2$ .
- En b), las distancias entre puntos del espacio de variables canónicas  $(v_{1,i}, v_{2,i}) = (\hat{\beta}_1^T \tilde{y}_i, \hat{\beta}_2^T \tilde{y}_i)$  dan aproximadamente la distancia de Mahalanobis entre observaciones  $\tilde{y}_i$ .



Planteo del problema

○○○  
○

Definiciones

○○○○○○○  
○○○○○○○○○

Estimación

○○○○○  
○○○○○○●○○

Criterio de Wilks

○○  
○○○

PCA regularizada

○○○○○  
○○○  
○○○  
○○○○○○○


CCA regularizada

○○○○○  
○○  
○○○○○○○


CCA rala

○○○

a)



b)



La relación entre  $u_j$  y  $v_j$  decrece con  $j$ , como esperábamos.

Cuando las variables en el modelo tienen desvíos estándar muy distintos, se usan los coeficientes estandarizados que se definen como

- $\hat{\alpha}_j^* = \hat{\Delta}_x^{1/2} \hat{\alpha}_j$ ,
- $\hat{\beta}_j^* = \hat{\Delta}_y^{1/2} \hat{\beta}_j$

permiten comparaciones más simples entre variables. Estas direcciones cumplen

$$\hat{\alpha}_j^{*T} \hat{\mathbf{R}}_{11} \hat{\alpha}_j^* = 1 \quad \hat{\beta}_j^{*T} \hat{\mathbf{R}}_{22} \hat{\beta}_j^* = 1$$

donde  $\hat{\mathbf{R}}_{11} = \hat{\Delta}_x^{-1/2} \mathbf{S}_{11} \hat{\Delta}_x^{-1/2}$  y  $\hat{\mathbf{R}}_{22} = \hat{\Delta}_y^{-1/2} \mathbf{S}_{22} \hat{\Delta}_y^{-1/2}$

	$\hat{\alpha}_1^*$	$\hat{\alpha}_2^*$	$\hat{\alpha}_3^*$
Control	-0.8404	-0.4166	-0.4435
Concept	0.2479	-0.8379	0.5833
Motivation	-0.4327	0.6948	0.6855
	$\hat{\beta}_1^*$	$\hat{\beta}_2^*$	$\hat{\beta}_3^*$
Read	-0.4508	-0.0496	0.2160
Write	-0.3490	0.4092	0.8881
Math	-0.2205	0.0398	0.0885
Science	-0.0488	-0.8266	-1.0661
Sex	-0.3150	0.5406	-0.8944

- En este caso, la interpretación es como sigue: para la variable *Read* un aumento de 1 desvío estándar en Lectura lleva a un decrecimiento de 0.45 desvíos estándar en la primer variable canónica  $\mathbf{v}_1$  cuando todas las demás variables permanecen constantes.
- Para las variables psicológicas, el primer vector canónico está fuertemente influenciado por Control (.84) y para  $\mathbf{u}_2$  por Concepto (-.84) and y Motivación (.69).
- Para las variables académicas más sexo,  $\mathbf{v}_1$  es un compromiso entre Lectura (.45), Escritura (.35) y Sexo (.32), mientras que para  $\mathbf{v}_2$  Escritura (.41), Ciencia (-.83) y Sexo (.54) son las variables dominantes.

## Criterio de Wilks

Tanto en el caso del test de independencia como en el modelo lineal multivariado es posible hallar dos matrices

- $\mathbf{U} \sim \mathcal{W}(\mathbf{\Sigma}, p, N - r)$  y
- $\mathbf{H} \sim \mathcal{W}(\mathbf{\Sigma}, p, r)$

independientes bajo la hipótesis nula de interés.

Más generalmente, tendremos

- $\mathbf{U} \sim \mathcal{W}(\mathbf{\Sigma}, p, N - r)$  y
- $\mathbf{z}_j \sim N(\boldsymbol{\mu}, \mathbf{\Sigma}), 1 \leq j \leq r, \mathbf{H} = \sum_{j=1}^r \mathbf{z}_j \mathbf{z}_j^T$

donde muchas veces  $r < p$  pero  $N - r > p$ .

El estadístico de Wilks se utiliza para testear cualquier hipótesis equivalente a  $\boldsymbol{\mu} = \mathbf{0}$ . Rechazaremos si el Wilks es pequeño.

## Criterio de Wilks

En analogía con el caso univariado Wilks (1932) definió el estadístico de Wilks.

**Definición** Sean  $\mathbf{U} \sim \mathcal{W}(\boldsymbol{\Sigma}, p, N - r)$  y  $\mathbf{z}_j \sim N(\mathbf{0}, \boldsymbol{\Sigma})$ ,  $1 \leq j \leq r$  independientes entre sí, el criterio de Wilks se define como

$$\Lambda(N, p, r) = \frac{|\mathbf{U}|}{|\mathbf{U} + \mathbf{H}|}$$

donde  $|\mathbf{A}|$  indica el determinante de la matriz  $\mathbf{A} \in \mathbb{R}^{p \times p}$  y  $\mathbf{H} = \sum_{j=1}^r \mathbf{z}_j \mathbf{z}_j^T \sim \mathcal{W}(\boldsymbol{\Sigma}, p, r)$

$N$ ,  $p$  y  $r$  son los parámetros del Wilks  $\Lambda$  y corresponden respectivamente a los grados de libertad de  $\mathbf{U} + \mathbf{H}$ , la dimensión de las matrices y los grados de libertad de  $\mathbf{H}$ .

Por otra parte, si  $\mathbf{U}$  es inversible  $\Lambda(N, p, r)$  depende sólo de los autovalores de  $\mathbf{H}\mathbf{U}^{-1}$ .

## Distribución del criterio de Wilks

a) Si  $r \geq p$ ,  $\mathbf{H} \sim \mathcal{W}(\mathbf{\Sigma}, p, r)$  tiene densidad y

$$\Lambda(N, p, r) \sim \prod_{j=1}^p b_{jj}^2$$

con  $b_{11}^2, \dots, b_{pp}^2$  son independientes  $b_{ii}^2 \sim \mathcal{B}\left(\frac{N-r+1-i}{2}, \frac{r}{2}\right)$

b) Si  $r < p$ ,

$$\Lambda(N, p, r) \sim \prod_{j=1}^r b_{jj}^2$$

con  $b_{11}^2, \dots, b_{rr}^2$  son independientes  $b_{ii}^2 \sim \mathcal{B}\left(\frac{N-p+1-i}{2}, \frac{p}{2}\right)$

Es decir,  $\Lambda(N, p, r) \sim \Lambda(N, r, p)$

## Corolario

a) Si  $p = 1$ ,

$$\frac{1 - \Lambda(N, 1, r)}{\Lambda(N, 1, r)} \frac{N - r}{r} \sim \mathcal{F}_{r, N-r}$$

b) Si  $r = 1$ ,

$$\frac{1 - \Lambda(N, p, 1)}{\Lambda(N, p, 1)} \frac{N - p}{p} \sim \mathcal{F}_{p, N-p}$$

c) Si  $p = 2$ ,

$$\frac{1 - \Lambda(N, 2, r)^{\frac{1}{2}}}{\Lambda(N, 2, r)^{\frac{1}{2}}} \frac{N - r - 1}{r} \sim \mathcal{F}_{2r, 2(N-r-1)}$$

d) Si  $r = 2$ ,

$$\frac{1 - \Lambda(N, p, 2)^{\frac{1}{2}}}{\Lambda(N, p, 2)^{\frac{1}{2}}} \frac{N - p - 1}{p} \sim \mathcal{F}_{2p, 2(N-p-1)}$$

## Aproximaciones a la Distribución del criterio de Wilks

- Rao (1951) mostró que

$$\frac{(fs + \lambda)}{m} \frac{(1 - \Lambda(N, p, r)^{\frac{1}{s}})}{\Lambda(N, p, r)^{\frac{1}{s}}} \approx \mathcal{F}_{m, fs + \lambda}$$

donde

$$\begin{aligned} f &= N - \frac{p + r + 1}{2} & m &= pr \\ \lambda &= -\frac{pr}{2} + 1 & s &= \frac{(p^2 r^2 - 4)^{\frac{1}{2}}}{(p^2 + r^2 - 5)^{\frac{1}{2}}} \end{aligned}$$



## Otros criterios

Hay otros criterios que se utilizan

- **Criterio de Roy** o de la máxima raíz. Considera la máxima raíz  $\theta_{\max}$  de  $|\mathbf{H} - \theta(\mathbf{U} + \mathbf{H})| = 0$ . Luego

$$\theta_{\max} = \frac{\lambda_1}{1 + \lambda_1}$$

y rechazo si  $\theta_{\max}$  es grande. Los percentiles de la distribución de  $\theta_{\max}$  están dados en el Apéndice D14 de Seber (1984).

## Test de Independencia $H_{01} : \Sigma = \text{diag}(\Sigma_{11}, \Sigma_{22})$

Supongamos  $\mathbf{z} \sim N(\boldsymbol{\mu}, \Sigma)$ .

Queremos testear  $\Sigma_{12} = 0$  o equivalentemente  $H_{01} : \rho_1 = 0$

El test de cociente de máxima verosimilitud para  $H_0$  está basado en

$$\gamma_1 = \frac{|\mathbf{Q}|}{|\mathbf{Q}_{11}| |\mathbf{Q}_{22}|} = \frac{|\mathbf{Q}_{11.2}|}{|\mathbf{Q}_{11}|}.$$

Vimos que

$$-n \log(\gamma_1) \xrightarrow{D} \chi_{\nu_1}^2$$

donde

$$\nu_1 = \frac{1}{2} (d^2 - (p^2 + q^2)) = pq.$$

La aproximación mejora si tomamos en lugar de  $n$  la corrección de Bartlett,  $m = n - (p + q + 3)/2$ , es decir,

$$-m \log(\gamma_1) \xrightarrow{D} \chi_{\nu_1}^2.$$

## Test de Independencia $H_{01} : \Sigma = \text{diag}(\Sigma_{11}, \Sigma_{22})$

Por otra parte,

$$|\mathbf{Q}| = |\mathbf{Q}_{22}| |\mathbf{Q}_{11.2}| = |\mathbf{Q}_{11}| |\mathbf{Q}_{22}| |\mathbf{I}_p - \mathbf{Q}_{11}^{-1} \mathbf{Q}_{12} \mathbf{Q}_{22}^{-1} \mathbf{Q}_{21}|$$

con lo cual

$$\gamma_1 = |\mathbf{I}_p - \mathbf{Q}_{11}^{-1} \mathbf{Q}_{12} \mathbf{Q}_{22}^{-1} \mathbf{Q}_{21}| = \prod_{j=1}^q (1 - r_j^2)$$

donde  $r_j^2$  son los autovalores de  $\mathbf{Q}_{12} \mathbf{Q}_{22}^{-1} \mathbf{Q}_{21} \mathbf{Q}_{11}^{-1}$ , o sea, el cuadrado de las correlaciones canónicas muestrales.

Es decir, rechazo con nivel  $\alpha$  si

$$\prod_{j=1}^q (1 - r_j^2) < k \ll 1$$

con  $k = \exp(-\chi_{1, \alpha}^2 / m)$  con  $m = n - (p + q + 3)/2$ .

## Test de Independencia $H_{01} : \Sigma = \text{diag}(\Sigma_{11}, \Sigma_{22})$

Por otra parte,

$$\gamma_1 = \frac{|\mathbf{Q}_{11.2}|}{|\mathbf{Q}_{11}|} = \frac{|\mathbf{U}|}{|\mathbf{U} + \mathbf{H}|}$$

donde  $\Sigma_{11.2} = \Sigma_{11} - \Sigma_{12}\Sigma_{22}^{-1}\Sigma_{21}$ . Ahora bien,

- $\mathbf{U} = \mathbf{Q}_{11.2} \sim \mathcal{W}(\Sigma_{11.2}, q, n - 1 - p) = \mathcal{W}(\Sigma_{11}, p, n - 1 - q)$  bajo  $H_{01}$
- $\mathbf{H} = \mathbf{Q}_{12}\mathbf{Q}_{22}^{-1}\mathbf{Q}_{21} \sim \mathcal{W}(\Sigma_{11.2}, p, q) = \mathcal{W}(\Sigma_{11}, p, q)$  bajo  $H_{01}$
- $\mathbf{H}$  y  $\mathbf{U}$  son independientes bajo  $H_{01}$ .

Luego,

$$\gamma_1 = \Lambda(n - 1, p, q)$$

## Test de Independencia $H_{01} : \Sigma = \text{diag}(\Sigma_{11}, \Sigma_{22})$

Queremos aplicar el principio de unión intersección de Roy para testear  $H_{01} : \Sigma_{12} = 0$ .

Recordemos que

$$\mathbf{z}_i = \begin{pmatrix} \mathbf{x}_i \\ \mathbf{y}_i \end{pmatrix}$$

entonces  $\text{COV}(\mathbf{a}^T \mathbf{x}, \mathbf{b}^T \mathbf{y}) = \mathbf{a}^T \Sigma_{12} \mathbf{b}$ . Definamos

$$H_{0,ab} : \mathbf{a}^T \Sigma_{12} \mathbf{b} = 0$$

Luego

$$H_{01} = \bigcap_{\mathbf{a} \neq \mathbf{0}} \bigcap_{\mathbf{b} \neq \mathbf{0}} H_{0,ab}$$

## Test de Independencia $H_{01} : \Sigma = \text{diag}(\Sigma_{11}, \Sigma_{22})$

Aplicando el principio de unión intersección, se obtiene el criterio de Roy.

Es decir, el test rechaza si

$$\theta_{\max} > k_{\alpha}.$$

donde  $\theta_{\max}$  es la máxima raíz de  $|\mathbf{H} - \theta(\mathbf{U} + \mathbf{H})| = 0$ , o sea,  $\theta_{\max}$  es el máximo autovalor de  $\mathbf{Q}_{12}\mathbf{Q}_{22}^{-1}\mathbf{Q}_{21}\mathbf{Q}_{11}^{-1}$ , es decir, rechaza si

$$r_1 > k_{\alpha}$$

## Determinando la cantidad de correlaciones canónicas

Aunque rechazemos  $H_{01} : \rho_1 = 0$  es posible que  $\rho_2 = 0$ , por lo tanto nos interesa testear

$$H_{0,k+1} : \rho_{k+1} = 0 \quad \rho_k > 0$$

que da la dimensión de la relación entre  $\mathbf{x}$  y  $\mathbf{y}$ .

- Si  $\rho_1 > 0$  y  $\rho_2 = 0$  la relación es lineal.
- Si  $\rho_1 > \rho_2 > 0$  y  $\rho_3 = 0$  la relación es planar.

El número de correlaciones no nulas da el rango de  $\Sigma_{12}$

Si  $\rho_1 \geq \dots \geq \rho_k > 0$  y  $\rho_{k+1} = 0$ , las variables canónicas asociadas a  $\rho_{k+1}$  se llaman **funciones nulas** y se usan en economía.

## Determinando la cantidad de correlaciones canónicas

El test de cociente de verosimilitud para

$$H_{0,k+1} : \rho_{k+1} = 0 \quad \rho_k > 0$$

se basa en

$$\gamma_{k+1} = \prod_{j=k+1}^q (1 - r_j^2)$$

Además,

$$\gamma_{k+1} = \Lambda(n-1-k, p-k, q-k)$$

Por la aproximación de Rao

$$\frac{(fs + \lambda)}{m} \frac{(1 - \gamma_{k+1}^{\frac{1}{s}})}{\gamma_{k+1}^{\frac{1}{s}}} \approx \mathcal{F}_{m, fs+\lambda} = \mathcal{F}_{\nu_{1,k+1}, \nu_{2,k+1}}$$

$$f = n - 3/2 - (p + q)/2$$

$$m = (p - k)(q - k)$$

$$\lambda = -\frac{(p - k)(q - k)}{2} + 1$$

$$s = \frac{((p - k)^2 (q - k)^2 - 4)^{\frac{1}{2}}}{((p - k)^2 + (q - k)^2 - 5)^{\frac{1}{2}}}$$



## Determinando la cantidad de correlaciones canónicas

El test de cociente de verosimilitud para

$H_{0,k+1} : \rho_{k+1} = 0 \quad \rho_k > 0$  se basa en

$$\gamma_{k+1} = \prod_{j=k+1}^q (1 - r_j^2)$$

Si  $H_{0,k+1}$  es cierta,

$$-n \log(\gamma_{k+1}) \xrightarrow{D} \chi_{\nu_{k+1}}^2 \quad \nu_{k+1} = (p - k)(q - k)$$

- Bartlett (1947) sugiere tomar  $m = n - (p + q + 3)/2$ , y usar la aproximación

$$-m \log(\gamma_{k+1}) \xrightarrow{D} \chi_{\nu_{k+1}}^2.$$

- Glynn y Muirhead (1978) sugieren la modificación

$$\ell_{k+1} = - \left[ n - k - \frac{p + q + 3}{2} + \sum_{j=1}^k \frac{1}{r_j^2} \right] \log(\gamma_{k+1}) \xrightarrow{D} \chi_{\nu_{k+1}}^2.$$

# Determinando la cantidad de correlaciones canónicas

Nos interesaba testear

$$H_{0,k+1} : \rho_{k+1} = 0 \quad \rho_k > 0$$

que da la dimensión de la relación entre  $\mathbf{x}$  y  $\mathbf{y}$ .

Para determinar  $k$  testamos la secuencia

$$H_{01}, H_{02}, \dots$$

hasta encontrar un test no significativo para digamos  $H_{0r}$  entonces elegimos  $k = r - 1$ .

## Ejemplo

Deseamos saber cuantas correlaciones son significativas

$H_{0,k+1}$	$\gamma_{k+1}$	$\mathcal{F}$	$\nu_{1,k+1}$	$\nu_{2,k+1}$	$p - valor$
$H_{01} : \rho_1 = 0$	0.7544	11.716	15	1635	$7.498e - 28$
$H_{02} : \rho_2 = 0(\rho_1 > 0)$	0.9614	2.944	8	1186	0.002905
$H_{03} : \rho_3 = 0(\rho_2 > 0)$	0.9892	2.165	3	594	0.09109



## Aproximación Asintótica

$H_{0,k+1}$	$\ell_{k+1}$	$\nu_{k+1}$	$p - valor$
$H_{01} : \rho_1 = 0$	167.580	15	0.00000000
$H_{02} : \rho_2 = 0(\rho_1 > 0)$	23.162	8	0.003163
$H_{03} : \rho_3 = 0(\rho_2 > 0)$	6.004	3	0.111401



a)


b)




- Porqué el gráfico en b) es una nube de puntos sin estructura?
- En a) cada punto es la correlación de la variable indicada con los ejes  $u_1$ ,  $u_2$ .
- En b), las distancias entre puntos del espacio de variables canónicas  $(u_{1,i}, u_{2,i}) = (\hat{\alpha}_1^T \tilde{\mathbf{x}}_i, \hat{\alpha}_2^T \tilde{\mathbf{x}}_i)$  dan aproximadamente la distancia de Mahalanobis entre observaciones  $\tilde{\mathbf{x}}_i$ .



a)



b)



- En a) cada punto es la correlación de la variable indicada con los ejes  $v_1$ ,  $v_2$ .
- En b), las distancias entre puntos del espacio de variables canónicas  $(v_{1,i}, v_{2,i}) = (\hat{\beta}_1^T \tilde{y}_i, \hat{\beta}_2^T \tilde{y}_i)$  dan aproximadamente la distancia de Mahalanobis entre observaciones  $\tilde{y}_i$ .

Planteo del problema

○○○  
○

Definiciones

○○○○○○○  
○○○○○○○○○

Estimación

○○○○○  
○○○○○○○○○

Criterio de Wilks

○○  
○○○

CCA regularizada

○○○○○  
○○○  
○○○●○○○


CCA regularizada

○○○○○  
○○  
○○○○○○○


CCA rala

○○○

a)



b)



La relación entre  $u_j$  y  $v_j$  decrece con  $j$ , como esperábamos.

## Vectores canónicos estandarizados

Espacio x			Espacio y		
	$\hat{\alpha}_1^*$	$\hat{\alpha}_2^*$		$\hat{\beta}_1^*$	$\hat{\beta}_2^*$
Control	-0.8404	-0.4166	Read	-0.4508	-0.0496
Concept	0.2479	-0.8379	Write	-0.3490	0.4092
Motivation	-0.4327	0.6948	Math	-0.2205	0.0398
			Science	-0.0488	-0.8266
			Sex	-0.3150	0.5406

- Para las variables psicológicas,
  - el primer vector canónico está fuertemente influenciado por Control (.84)
  - $\mathbf{u}_2$  está influenciado por Concepto (-.84) and y Motivación (.69).
- Para las variables académicas más sexo,
  - $\mathbf{v}_1$  es un compromiso entre Lectura (.45), Escritura (.35) y Sexo (.32),
  - para  $\mathbf{v}_2$  Escritura (.41), Ciencia (-.83) y Sexo (.54) son las variables dominantes.

## Qué pasa si $p$ crece con $n$ ?

- Fujikoshi *et al.* (2008) Asymptotic results in canonical discriminant analysis when the dimension is large compared to the sample size. *Journal of Statistical Planning and Inference* **128**,3457-3466.
- Fujikoshi, Y. (2016). High-Dimensional asymptotic distributions of characteristic roots in multivariate linear models and canonical correlation analysis.
- Fujikoshi *et al.* (2010) *Multivariate Statistics: High-dimensional and large-sample approximations*
- Bao *et al.* (2017). Canonical correlation coefficients of high-dimensional Gaussian vectors: finite rank case. En prensa en *Annals of Statistics*.

Obtuvieron la distribución asintótica de las correlaciones canónicas cuando  $q$  es fijo y  $p/n \rightarrow c \in (0, 1)$



## Qué pasa si $p$ crece con $n$ ?

- Oda *et al.* (2016). Asymptotic non-null distributions of test statistics for redundancy in the high-dimensional canonical correlation analysis.

Considera el problema de testear redundancia si  $(p + q)/n \rightarrow c \in (0, 1)$

- C. Gao, Z. Ma, Z. Ren, HH Zhou. (2015). Minimax estimation in sparse canonical correlation analysis. *Annals of Statistics*, **43**, 2168-2197.
- C. Gao, Z. Ma, HH Zhou. (2014). Sparse CCA: Adaptive estimation and computational barriers.

Consideran el caso ralo pero con  $(p + q)/n \rightarrow c \in (0, 1)$ .

Supongamos que

- $n < \min(p, q)$

o

- las componentes del vector  $\mathbf{x} = (x_1, \dots, x_p)^T$  o del vector  $\mathbf{y} = (y_1, \dots, y_q)^T$  son casi colineales.

En ese caso, **las matrices  $\mathbf{S}_{11}$  y/o  $\mathbf{S}_{22}$  son singulares.**

No podemos definir

- $\mathbf{u}_i = (u_{1,i}, \dots, u_{q,i})^T$  con  $u_{j,i} = \hat{\alpha}_j^T \tilde{\mathbf{x}}_i$  y
- $\mathbf{v}_i = (v_{1,i}, \dots, v_{q,i})^T$   $v_{j,i} = \hat{\beta}_j^T \tilde{\mathbf{y}}_i$

como

$$\mathbf{S}_{11}^{-1} \mathbf{S}_{12} \mathbf{S}_{22}^{-1} \mathbf{S}_{21} \hat{\alpha}_j = r_j^2 \hat{\alpha}_j$$

$$\hat{\alpha}_j^T \mathbf{S}_{11} \hat{\alpha}_j = 1$$

$$\mathbf{S}_{22}^{-1} \mathbf{S}_{21} \mathbf{S}_{11}^{-1} \mathbf{S}_{12} \hat{\beta}_j = r_j^2 \hat{\beta}_j$$

$$\hat{\beta}_j^T \mathbf{S}_{22} \hat{\beta}_j = 1$$

## CCA Ridge

Propuesto por

- Vinod, H. (1976), Canonical ridge and econometrics of joint production. *Journal of Econometrics*, **4**, 147-166.

Reemplaza las matrices

$$\mathbf{S}_{11} \quad y \quad \mathbf{S}_{22}$$

por

$$\mathbf{S}_{11}(\lambda_1) = \mathbf{S}_{11} + \lambda_1 \mathbf{I}_p \quad y \quad \mathbf{S}_{22}(\lambda_2) = \mathbf{S}_{22} + \lambda_2 \mathbf{I}_q$$

## CCA Ridge

Es decir, resolvemos

$$\mathbf{S}_{11}(\lambda_1)^{-1} \mathbf{S}_{12} \mathbf{S}_{22}(\lambda_2)^{-1} \mathbf{S}_{21} \hat{\alpha}_j = r_j^2 \hat{\alpha}_j$$

$$\hat{\alpha}_j^T \mathbf{S}_{11}(\lambda_1) \hat{\alpha}_j = 1$$

$$\mathbf{S}_{22}(\lambda_2)^{-1} \mathbf{S}_{21} \mathbf{S}_{11}(\lambda_1)^{-1} \mathbf{S}_{12} \hat{\beta}_j = r_j^2 \hat{\beta}_j$$

$$\hat{\beta}_j^T \mathbf{S}_{22}(\lambda_2) \hat{\beta}_j = 1$$

Equivalentemente, para encontrar  $(\hat{\alpha}_1, \hat{\beta}_1) = (\hat{\alpha}_1(\lambda_1, \lambda_2), \hat{\beta}_1(\lambda_1, \lambda_2))$  maximizamos

$$\max_{\alpha \neq \mathbf{0}_p, \beta \neq \mathbf{0}_q} \hat{\rho}_{\alpha, \beta}^2(\lambda_1, \lambda_2) = \max_{\alpha \neq \mathbf{0}_p, \beta \neq \mathbf{0}_q} \frac{(\alpha^T \mathbf{S}_{12} \beta)^2}{(\alpha^T \mathbf{S}_{11}(\lambda_1) \alpha) (\beta^T \mathbf{S}_{22}(\lambda_2) \beta)}$$

Como en regresión ridge al agregar las penalizaciones  $\lambda_1$  y  $\lambda_2$  a los elementos diagonales de  $\mathbf{S}_{11}$  y  $\mathbf{S}_{22}$  se obtienen estimadores más estables y confiables cuando los datos están cerca de la colinealidad.

## CCA Ridge

- $\hat{\rho}_{\alpha, \beta}^2(\lambda_1, \lambda_2) \leq \hat{\rho}_{\alpha, \beta}^2(0, 0)$

- Como la condición de vínculo es

$$\hat{\alpha}_1^T \mathbf{S}_{11}(\lambda_1) \hat{\alpha}_1 = \hat{\beta}_1^T \mathbf{S}_{22}(\lambda_2) \hat{\beta}_1 = 1$$

entonces

$$\|\hat{\alpha}_1(\lambda_1, \lambda_2)\| \leq \|\hat{\alpha}_1(0, 0)\| \quad \|\hat{\beta}_1(\lambda_1, \lambda_2)\| \leq \|\hat{\beta}_1(0, 0)\|$$

## CCA Ridge

Estamos resolviendo un problema de regresión ridge alternado

- Fijado  $\hat{\beta}_1$  si  $\hat{v}_{1,i} = \hat{\beta}_1^T \tilde{\mathbf{y}}_i$
- $\hat{\alpha}_1$  resuelve

$$\hat{\alpha}_1 = \underset{\alpha \neq \mathbf{0}_p}{\operatorname{argmin}} \sum_{i=1}^n (\hat{v}_{1,i} - \alpha^T \tilde{\mathbf{x}}_i)^2 + \lambda_1 \|\alpha\|^2$$

- Fijado  $\hat{\alpha}_1$  si  $\hat{u}_{1,i} = \hat{\alpha}_1^T \tilde{\mathbf{x}}_i$
- $\hat{\beta}_1$  resuelve

$$\hat{\beta}_1 = \underset{\beta \neq \mathbf{0}_q}{\operatorname{argmin}} \sum_{i=1}^n (\hat{u}_{1,i} - \beta^T \tilde{\mathbf{y}}_i)^2 + \lambda_2 \|\beta\|^2$$

Hasta convergencia.

Cómo elegir  $\lambda_1$  y  $\lambda_2$ ,  $\boldsymbol{\lambda} = (\lambda_1, \lambda_2)^T$

- Para cada  $1 \leq i \leq n$ , sea la muestra sin la observación  $i$ -ésima, o sea,  $\{(\mathbf{x}_j, \mathbf{y}_j)\}_{j \neq i}$  e indiquemos por

$$\mathbf{S}^{(-i)} = \frac{1}{n-1} \sum_{j \neq i} \left( \mathbf{z}_j - \bar{\mathbf{z}}^{(-i)} \right) \left( \mathbf{z}_j - \bar{\mathbf{z}}^{(-i)} \right)^T = \begin{pmatrix} \mathbf{S}_{11}^{(-i)} & \mathbf{S}_{12}^{(-i)} \\ \mathbf{S}_{21}^{(-i)} & \mathbf{S}_{22}^{(-i)} \end{pmatrix}$$

- Definamos  $(\hat{\alpha}_1^{(-i)}(\lambda), \hat{\beta}_1^{(-i)}(\lambda))$  los valores tales que

$$\begin{aligned} \left( \widehat{\alpha}_1^{(-i)}(\lambda), \widehat{\beta}_1^{(-i)}(\lambda) \right) &= \underset{\substack{\alpha^T \mathbf{s}_{11}^{(-i)}(\lambda_1) \alpha = 1 \\ \beta^T \mathbf{s}_{22}^{(-i)}(\lambda_2) \beta = 1}}{\operatorname{argmax}} \left( \widehat{\rho}_{\alpha, \beta}^{(-i)}(\lambda_1, \lambda_2) \right)^2 \\ &= \underset{\substack{\alpha^T \mathbf{s}_{11}^{(-i)}(\lambda_1) \alpha = 1 \\ \beta^T \mathbf{s}_{22}^{(-i)}(\lambda_2) \beta = 1}}{\operatorname{argmax}} \left( \alpha^T \mathbf{s}_{12}^{(-i)} \beta \right)^2 \end{aligned}$$

- Sean

$$u_i^{(-i)} = \mathbf{x}_i^T \hat{\boldsymbol{\alpha}}_1^{(-i)}(\boldsymbol{\lambda}) \quad v_i^{(-i)} = \mathbf{y}_i^T \hat{\boldsymbol{\beta}}_1^{(-i)}(\boldsymbol{\lambda})$$


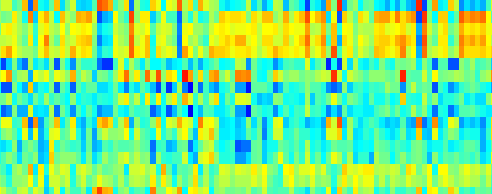
- Definamos

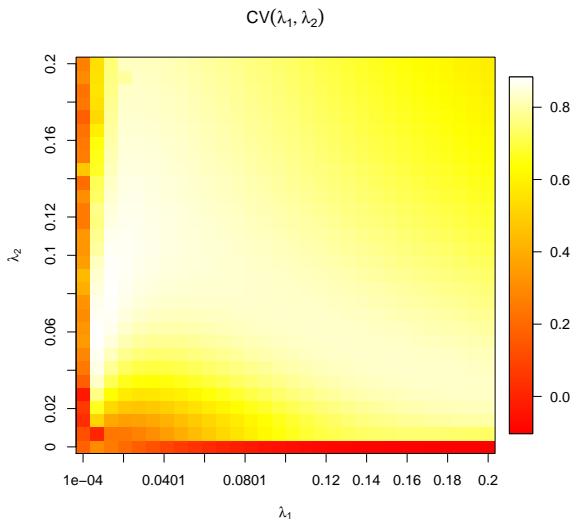
$$\begin{aligned} CV(\boldsymbol{\lambda}) &= \text{cor} \left( \{u_{1,i}^{(-i)}\}_{1 \leq i \leq n}, \{v_{1,i}^{(-i)}\}_{1 \leq i \leq n} \right) \\ &= \frac{\sum_{i=1}^n (u_{1,i}^{(-i)} - \bar{u}^{(-i)})(v_{1,i}^{(-i)} - \bar{v}^{(-i)})}{\left\{ \sum_{i=1}^n (u_{1,i}^{(-i)} - \bar{u}^{(-i)})^2 \sum_{i=1}^n (v_{1,i}^{(-i)} - \bar{v}^{(-i)})^2 \right\}^{\frac{1}{2}}} \end{aligned}$$

$$\hat{\boldsymbol{\lambda}} = \underset{\boldsymbol{\lambda}}{\operatorname{argmax}} CV^2(\boldsymbol{\lambda})$$












$$\hat{\lambda}_1 = 0.006993103 \quad \hat{\lambda}_2 = 0.06206897 \quad CV(\hat{\lambda}) = 0.8837507$$



Planteo del problema	Definiciones	Estimación	Criterio de Wilks	Inferencia	CCA regularizada	CCA rala
ooo o	oooooooo oooooooooooo	ooooo oooooooooooo	oo oooo	ooooo oooo ooooo	ooooo oooo oooo●ooo	ooo ooo



Planteo del problema

ooo  
o

Definiciones

oooooooo  
oooooooooooo

Estimación

ooooo  
oooooooooooo

Criterio de Wilks

oo  
oooo

Inferencia


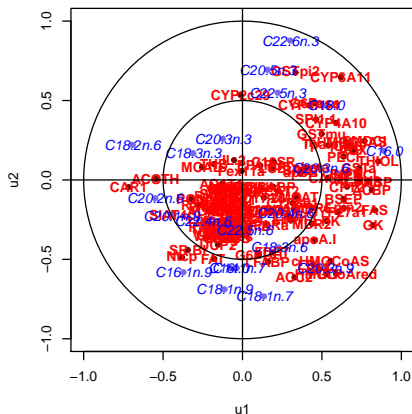
ooooo  
oooo  
ooooo

CCA regularizada

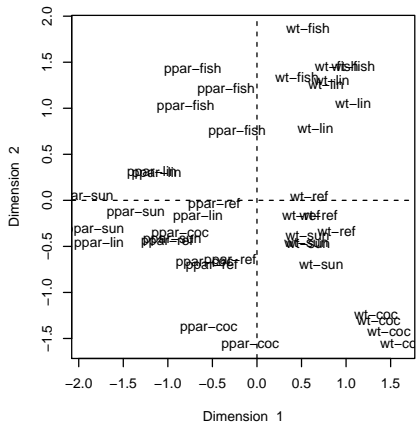

ooooo  
oo  
ooooo●o

CCA rala

oo



Planteo del problema	Definiciones	Estimación	Criterio de Wilks	Inferencia	CCA regularizada	CCA rala
ooo o	oooooooo oooooooooooo	ooooo oooooooooooo	oo oooo	ooooo oooo ooooo	ooooo oooo ooooo●	oo oo



## CCA rala

Otra aproximación es usar CCA rala.

- Parkhomenko *et al.* (2009) Sparse canonical correlation analysis with application to genomic data integration. *Statistical Applications in Genetics and Molecular Biology*, **8**, 1-34.
- Witten *et al.* (2009). A penalized matrix decomposition, with applications to sparse principal components and canonical correlation analysis. *Biostatistics*, **10**, 515-534.
- Waaijenborg *et al.* (2008). Quantifying the association between gene expressions and DNA-markers by penalized canonical correlation analysis. *Statistical Applications in Genetics and Molecular Biology*, **7**, Article 3.

Usan distintos tipos de penalizaciones (LASSO, elastic net) pero suponen que  $\Sigma_{11} = \mathbf{I}$  y  $\Sigma_{22} = \mathbf{I}$ , lo que ignora dependencia entre las variables de cada grupo.



## CCA rala

- Wilms, I. and Croux, C. (2015). Sparse canonical correlation analysis from a predictive point of view. *Biometrical Journal*, **57**, 834-851

Usa un enfoque de regresión LASSO alternada.

## CCA rala

- Fijado  $\hat{\beta}_1$  si  $\hat{v}_{1,i} = \hat{\beta}_1^T \tilde{\mathbf{y}}_i$
- $\hat{\alpha}_1$  resuelve

$$\hat{\alpha}_1 = \underset{\alpha \neq \mathbf{0}_p}{\operatorname{argmin}} \sum_{i=1}^n (\hat{v}_{1,i} - \alpha^T \tilde{\mathbf{x}}_i)^2 + \lambda_1 \sum_{\ell=1}^p |\alpha_\ell|$$

- Fijado  $\hat{\alpha}_1$  si  $\hat{u}_{1,i} = \hat{\alpha}_1^T \tilde{\mathbf{x}}_i$
- $\hat{\beta}_1$  resuelve

$$\hat{\beta}_1 = \underset{\beta \neq \mathbf{0}_q}{\operatorname{argmin}} \sum_{i=1}^n (\hat{u}_{1,i} - \beta^T \tilde{\mathbf{y}}_i)^2 + \lambda_2 \sum_{\ell=1}^q |\beta_\ell|$$