


Componentes Principales Funcionales (FPCA)

Parte 2


Graciela Boente

Densidad ósea: Hombres

Trayectorias Largas




Trayectorias Cortas



CD4

- Conteos de CD4 en 369 pacientes de SIDA.
- El número de mediciones por individuo varía de 1 a 12, con número mediano de conteos igual a 6
- Ejemplo de datos funcionales esparsos medidos en tiempos diferentes e irregulares para cada individuo



Extraído y se agradece a Wang, J.L., Chiou, J., Müller, H.G. (2016). Functional Data Analysis. *Annual Review of*

PACE = Principal Analysis by Conditional Estimation

Supongamos que

$$Y_{ij} = X_i(t_{ij}) \quad 1 \leq j \leq n_i \quad 1 \leq i \leq N$$

También consideran el caso de errores de medición, es decir, se tiene un proceso $X(t)$ tal que $\mathbb{E}X(t) = \mu(t)$ y $\text{Cov}(X(s), X(t)) = \gamma(s, t)$ y observamos

$$Y_{ij} = X_i(t_{ij}) + \epsilon_{ij} \quad 1 \leq j \leq n_i \quad 1 \leq i \leq N$$

- ϵ_{ij} son i.i.d. independientes de X_i y de los tiempos (que pueden ser aleatorios)

PACE (Yao, Müller & Wang, 2005)


- **Paso 1** Empezaremos estimando μ mediante un polinomio local, o sea, para cada $t_0 \in \mathcal{I}$, sean

$$\left(\hat{\beta}_0(t_0), \hat{\beta}_1(t_0) \right)^T = \underset{\beta_0, \beta_1}{\operatorname{argmin}} \sum_{i=1}^N \sum_{j=1}^{n_i} \mathcal{K} \left(\frac{t_{ij} - t_0}{h} \right) (Y_{ij} - \beta_0 - \beta_1(t_0 - t_{ij}))^2,$$


- $\mathcal{K} : \mathbb{R} \rightarrow \mathbb{R}$ es un núcleo, o sea, $\mathcal{K} \geq 0$, $\int \mathcal{K}(u) du < \infty$, \mathcal{K} es continua
- $h = h_n$ es la ventana o parámetro de suavizado.
- El estimador de $\mu(t_0)$ es igual a

$$\hat{\mu}(t_0) = \hat{\beta}_0(t_0).$$

Densidad Osea: $\hat{\mu}$, $h = 0.85$




CD4: $\hat{\mu}$, $h = 0.3$



El estimador de la media $\hat{\mu}$ muestra que

- los conteos de CD4 son estables hasta 6 meses antes de la seroconversión (tiempo 0),
- baja seis meses antes y después de la seroconversión y
- se estabiliza nuevamente, un año después de la seroconversión.

CD4



- Aunque los datos por individuo son raros,
- Los datos combinados llenan el dominio de la superficie $\gamma(s, t)$ bastante densamente

Extraído y se agradece a Yao, F., Müller, H.G., Wang, J.L. (2005). Functional data analysis for sparse longitudinal data. *J. American Statistical Association*, **100**, 577-590.

PACE (Yao, Müller & Wang, 2005)

**Supongamos primero que
no hay errores de
medición, o sea, para
 $1 \leq i \leq N$**

$$Y_{ij} = X_i(t_{ij}) \quad 1 \leq j \leq n_i$$

PACE (Yao, Müller & Wang, 2005)

- Paso 2** Como

$$\begin{aligned}\gamma(s, t) &= \text{Cov}(X(s), X(t)) \\ &= \mathbb{E}\left[(X(s) - \mu(s))(X(t) - \mu(t))\right]\end{aligned}$$

uno puede estimar $\gamma(s, t)$ usando un smoother bivariado de los productos cruzados (*covarianzas crudas*)

$$\hat{\gamma}_{ij\ell} = (X_i(t_{ij}) - \hat{\mu}(t_{ij}))(X_i(t_{i\ell}) - \hat{\mu}(t_{i\ell})) = (Y_{ij} - \hat{\mu}(t_{ij}))(Y_{i\ell} - \hat{\mu}(t_{i\ell}))$$

$$\longrightarrow \hat{\gamma}(s, t) \longrightarrow \hat{\lambda}_k, \hat{\phi}_k$$

PACE (Yao, Müller & Wang, 2005)

- **Paso 3** Los escores $\xi_{ij} = \langle X_i - \mu, \phi_j \rangle$ no se pueden aproximar por

$$\sum_{\ell} (X_i(t_{i\ell}) - \hat{\mu}(t_{i\ell})) \hat{\phi}_j(t_{i\ell}) ((t_{i\ell}) - (t_{i(\ell-1)}))$$

pues hay pocos puntos!!

- $\mathbf{t} = (t_1, \dots, t_m)^T$, $\mathbf{X} = (X(t_1), \dots, X(t_m))^T$.

- Si las observaciones son Gaussianas

$$\mathbb{E}(\xi_k | \mathbf{X}) = \lambda_k \phi_k^T \Sigma^{-1} (\mathbf{X} - \mu)$$

- $\phi_k = (\phi_k(t_1), \dots, \phi_k(t_m))^T$,

- $\mu = (\mu(t_1), \dots, \mu(t_m))^T$

- el elemento (ℓ, j) de Σ es $\gamma(t_\ell, t_j)$.

PACE (Yao, Müller & Wang, 2005)

- Paso 3:** $\mathbf{t}_i = (t_{i1}, \dots, t_{in_i})^T$.

$$\hat{\xi}_{ik} = \hat{\lambda}_k \hat{\phi}_k^T \hat{\Sigma}^{-1} (\mathbf{X}_i - \hat{\mu}_i)$$

- $\mathbf{X}_i = (X_i(t_{i1}), \dots, X_i(t_{in_i}))^T$
- $\hat{\phi}_k = (\hat{\phi}_k(t_{i1}), \dots, \hat{\phi}_k(t_{in_i}))^T$,
- $\hat{\mu}_i = (\hat{\mu}(t_{i1}), \dots, \hat{\mu}(t_{in_i}))^T$
- el elemento (ℓ, j) de $\hat{\Sigma}$ es $\hat{\gamma}(t_{i\ell}, t_{ij})$.

-

$$\hat{X}_i(t) = \hat{\mu}(t) + \sum_{k=1}^q \hat{\xi}_{ik} \hat{\phi}_k(t)$$

$$\mathbb{E}(\xi_k | \mathbf{X}) = \lambda_k \phi_k^T \Sigma^{-1} (\mathbf{X} - \mu)$$

- Para cada $s \in \mathcal{I}$, $(X(s) - \mu(s), X(t_1), X(t_2), \dots, X(t_m))^T$ tiene distribución normal multivariada $N((0, \mu^T)^T, \Sigma_1)$ donde

$$\Sigma_1 = \begin{pmatrix} \gamma(s, s) & (\gamma(s, t_1), \dots, \gamma(s, t_m)) \\ (\gamma(s, t_1), \dots, \gamma(s, t_m))^T & \Sigma \end{pmatrix}.$$

- Si llamamos $\gamma(s) = (\gamma(s, t_1), \dots, \gamma(s, t_m))^T$, tenemos que

$$\begin{aligned} \mathbb{E}(\xi_k | \mathbf{X}) &= \mathbb{E}(\langle X - \mu, \phi_k \rangle | \mathbf{X}) = \langle \mathbb{E}(X - \mu | \mathbf{X}), \phi_k \rangle \\ &= \int_{\mathcal{I}} \phi_k(s) \mathbb{E}(X(s) - \mu(s) | \mathbf{X}) ds \\ &= \int_{\mathcal{I}} \phi_k(s) \gamma(s)^T ds \Sigma^{-1} (\mathbf{X} - \mu) \\ &= \lambda_k (\phi_k(t_1), \dots, \phi_k(t_m))^T \Sigma^{-1} (\mathbf{X} - \mu). \end{aligned}$$

PACE (Yao, Müller & Wang, 2005)

Supongamos ahora que hay errores de medición

$$Y_{ij} = X_i(t_{ij}) + \epsilon_{ij} \quad 1 \leq j \leq n_i$$

PACE (Yao, Müller & Wang, 2005)

- **Paso 2** Recordemos que

$$\begin{aligned}\gamma(s, t) &= \text{Cov}(X(s), X(t)) \\ &= \mathbb{E} \left[(X(s) - \mu(s)) (X(t) - \mu(t)) \right]\end{aligned}$$

Luego,

$$\begin{aligned}\text{Cov}(Y_{ij}, Y_{i\ell}) &= \text{Cov}(X_i(t_{ij}), X_i(t_{i\ell})) + \text{Cov}(\epsilon_{ij}, \epsilon_{i\ell}) \\ &= \gamma(t_{ij}, t_{i\ell}) + \sigma^2 \delta_{j\ell}\end{aligned}$$

PACE (Yao, Müller & Wang, 2005)

- **Paso 2:** Los elementos diagonales de las covarianzas crudas

$$G_i(t_{ij}, t_{i\ell}) = (Y_{ij} - \hat{\mu}(t_{ij}))(Y_{i\ell} - \hat{\mu}(t_{i\ell}))$$

deben ser eliminados al suavizar.

- O sea suavizamos, $G_{i,j\ell}$ para $j \neq \ell$. Para ello definamos

$$H(\beta_0, \beta_1, \beta_2) = \sum_{i=1}^N \sum_{1 \leq j \neq \ell \leq n_i} \mathcal{K}\left(\frac{t_{ij} - s}{h_G}\right) \mathcal{K}\left(\frac{t_{i\ell} - t}{h_G}\right) \\ \times (G_i(t_{ij}, t_{i\ell}) - \beta_0 - \beta_1(s - t_{ij}) - \beta_2(t - t_{i\ell}))^2$$

- Sea $(\hat{\beta}_0, \hat{\beta}_1, \hat{\beta}_2) = \operatorname{argmin} H(\beta_0, \beta_1, \beta_2)$, definimos

$$\hat{\gamma}(s, t) = \hat{\beta}_0 = \hat{\beta}_0(s, t).$$

PACE (Yao, Müller & Wang, 2005)

- **Paso 2:** Para obtener el estimador de $\gamma(t, t)$
 - Primero se rotan los ejes de los tiempos 45 grados obteniendo

$$\begin{pmatrix} t_{ij}^* \\ t_{i\ell}^* \end{pmatrix} = \frac{1}{\sqrt{2}} \begin{pmatrix} 1 & 1 \\ -1 & 1 \end{pmatrix} \begin{pmatrix} t_{ij} \\ t_{i\ell} \end{pmatrix}$$

- Definimos $\tilde{\gamma}(s, t)$ minimizando en (ν_0, ν_1, ν_2) la cantidad

$$H_1(\nu_0, \nu_1, \nu_2) = \sum_{i=1}^N \sum_{1 \leq j \neq \ell \leq n_i} \mathcal{K} \left(\frac{t_{ij}^* - s}{h_G} \right) \mathcal{K} \left(\frac{t_{i\ell}^* - t}{h_G} \right) \\ \times \left(G_i(t_{ij}^*, t_{i\ell}^*) - \nu_0 - \nu_1 (s - t_{ij}^*) - \nu_2 (t - t_{i\ell}^*)^2 \right)^2$$

obteniendo $\tilde{\gamma}(s, t) = \hat{\nu}_0 = \hat{\nu}_0(s, t)$

- Debido a la rotación el estimador de $\gamma(t, t)$ es

$$\hat{\gamma}(t, t) = \tilde{\gamma}(\sqrt{2}t, 0)$$

PACE (Yao, Müller & Wang, 2005)

- Paso 2: continuación**

- Sea $\widehat{V}(t)$ un smoother lineal de los elementos diagonales, es decir,

$$\widehat{V}(t) = \widehat{\alpha}_0$$

donde

$$(\widehat{\alpha}_0, \widehat{\alpha}_1) = \underset{(\alpha_0, \alpha_1)}{\operatorname{argmin}} \sum_{i=1}^N \sum_{1 \leq j \leq n_i} \mathcal{K} \left\{ \frac{t_{ij} - t}{h_G} \right\} \{G_i(t_{ij}, t_{ij}) - \alpha_0 - \alpha_1 (t - t_{ij})\}^2$$

- Estimamos σ^2 por

$$\widehat{\sigma}^2 = \frac{1}{|\mathcal{I}|} \int_{\mathcal{I}} \left\{ \widehat{V}(t) - \widehat{\gamma}(t, t) \right\} dt$$

si $\widehat{\sigma}^2 > 0$ y $\widehat{\sigma}^2 = 0$ otro caso.

PACE (Yao, Müller & Wang, 2005)

- **Paso 3:** Los escores $\xi_{ij} = \langle X_i - \mu, \phi_j \rangle$ no se pueden aproximar por

$$\sum_{\ell} (X_i(t_{i\ell}) - \hat{\mu}(t_{i\ell})) \hat{\phi}_j(t_{i\ell}) ((t_{i\ell}) - (t_{i(\ell-1)}))$$

pues hay pocos puntos!!

- $\mathbf{t}_i = (t_{i1}, \dots, t_{in_i})^T$.

$$\hat{\xi}_{ik} = \hat{\lambda}_k \hat{\phi}_k^T \hat{\Sigma}_{\mathbf{Y}_i}^{-1} (\mathbf{Y}_i - \hat{\mu}_i) \quad \mathbf{Y}_i = (Y_{i1}, \dots, Y_{in_i})^T$$

- El elemento (j, ℓ) de $\hat{\Sigma}_{\mathbf{Y}_i}$ es


$$\hat{\gamma}(t_{ij}, t_{i\ell}) + \hat{\sigma}^2 \delta_{j\ell}$$

- $\hat{X}_i(t) = \hat{\mu}(t) + \sum_{k=1}^q \hat{\xi}_{ik} \hat{\phi}_k(t)$

FPCA esparso


- Selección de las ventanas:
 - Convalidación cruzada
- Selección del número de direcciones principales q
 - Proporción de la variabilidad explicada

CD4: $h = 1.4$







- Los puntos son las covarianzas *crudas*
- Superficie $\hat{\gamma}$ obtenida omitiendo los datos en la diagonal
- la diagonal forma una cresta debido a los errores de medición en los datos.

CD4: $\hat{\phi}_j$




- La primer dirección es casi constante. Luego, la primer componente es en la magnitud media específica de los conteos de CD4.
- La segunda dirección muestra una variación alrededor de una tendencia temporal lineal por partes con un punto de corte cercano a 2.5 años después de la seroconversión, lo que refleja que la segunda componente es una diferencia de escala entre sujetos a lo largo de la dirección de esta función lineal por partes.

CD4: $\hat{\phi}_j$




Lip Data


Trayectorias (32) del centro del labio inferior de un individuo que pronuncia repetidamente la palabra *BOB* (Malfait & Ramsay, 2003 and Gervini, 2008)



Lip Data - Functional boxplot




Lip Data




Lip Data: $\hat{\phi}_1$

Todos los datos




Sin observaciones 24, 25 y 27




Lip Data: $\hat{\phi}_2$

Todos los datos




Sin observaciones 24, 25 y 27




Ozone data


- Mediciones horarios del nivel de concentración de Ozono (O_3 ppb)
- Agosto, 2004 a 2012, 176 días con mediciones horarias promedio
- Máximo nivel deseado establecido por el Canadian National Ambient Air Quality Objectives: 50 ppb




Richmond Ozone - Functional boxplot



Richmond Ozone




Richmond Ozone




Richmond Ozone: $\hat{\phi}_1$

Todos los datos




Sin observaciones 1, 24, 25, 29 y 165






Richmond Ozone: $\hat{\phi}_2$

Todos los datos



Sin observaciones 1, 24, 25, 29 y 165




Richmond Ozone: $\hat{\phi}_j$ $\hat{\phi}_1$  $\hat{\phi}_2$ 

En negro: las estimaciones con todos los datos


En rojo: las estimaciones sin las observaciones 1, 24, 25, 29 y 165

Richmond Ozone: $\hat{\phi}_j$

$\hat{\phi}_3$



$\hat{\phi}_4$



En negro: las estimaciones con todos los datos

En rojo: las estimaciones sin las observaciones 1, 24, 25, 29 y 165

Componentes principales esféricas

Por qué funcionan las componentes principales esféricas?

- $\hat{\Gamma}^S \xrightarrow{a.s.} \Gamma^S = \mathbb{E} \left(\frac{(X - \mu) \otimes (X - \mu)}{\|X - \mu\|^2} \right)$
- Γ^S tiene las mismas autofunciones que Γ si
 - $X \sim \mathcal{E}(\mu, \Gamma, \varphi)$
Boente, Salibián-Barrera & Tyler (2014)
 - $X = \mu + \sum_{j=1}^p Z_j \lambda_j^{1/2} \phi_j$ y $\mathbf{Z} = (Z_1, \dots, Z_p)$ tiene marginales simétricas e intercambiables.
Gervini (2008)

$$\bullet \quad \Gamma^S = \mathbb{E} \left(\frac{(\mathbf{X} - \mu) \otimes (\mathbf{X} - \mu)}{\|\mathbf{X} - \mu\|^2} \right) = \sum_{\ell \geq 1} \lambda_{\ell}^S \phi_{\ell} \otimes \phi_{\ell}$$

$$\lambda_{\ell}^S = \lambda_{\ell} \mathbb{E} \left(\frac{Z_{\ell}^2}{\sum_{s \geq 1} \lambda_s Z_s^2} \right).$$

Propiedad 2: “Direcciones” de máxima variabilidad

- $s_n(\alpha)$ una escala robusta de la muestra $\{\langle \alpha, X_i \rangle\}_{i=1}^n$
 - MAD
 - M –escala, es decir, si $Y_i = \langle \alpha, X_i - \hat{\mu} \rangle$, el M –estimador de escala es la solución $s_n(\alpha)$ de

$$\frac{1}{n} \sum_{i=1}^n \rho \left(\frac{Y_i}{s_n(\alpha)} \right) = \delta .$$

- El estimador de la primer dirección principal se define como

$$\hat{\phi}_1 = \operatorname{argmax}_{\|\alpha\|=1} s_n^2(\alpha)$$

- Los siguientes como

$$\hat{\phi}_m = \operatorname{argmax}_{\alpha \in \hat{\mathcal{B}}_m} s_n^2(\alpha) \quad 2 \leq m,$$

$$\hat{\mathcal{B}}_m = \{\alpha \in \mathcal{H} : \|\alpha\| = 1, \langle \alpha, \hat{\phi}_j \rangle = 0, \forall 1 \leq j \leq m-1\}.$$

- $\hat{\lambda}_m = s_n^2(\hat{\phi}_m)$

Un enfoque PP suavizado

- A veces nos interesan direcciones principales suaves.
 - $D : \mathcal{H}_S \rightarrow \mathcal{H}$ un operador lineal (“diferenciador”, e.g., $D\alpha = \alpha''$ when $\mathcal{H} = L^2(\mathcal{I})$).
 - Permite definir un producto interno de penalización $[\alpha, \beta] = \langle D\alpha, D\beta \rangle$.
 - “Operador de penalización ” $\Psi : \mathcal{H}_S \rightarrow \mathbb{R}$, $\Psi(\alpha) = [\alpha, \alpha]$
 - Producto interno penalizado $\langle \alpha, \beta \rangle_\tau = \langle \alpha, \beta \rangle + \tau [\alpha, \beta]$.
 - Norma penalizada $\|\alpha\|_\tau^2 = \|\alpha\|^2 + \tau \Psi(\alpha)$

Un enfoque unificado robusto via PP

- Algunas veces en lugar de las direcciones principales empíricas, interesa obtener direcciones principales suaves.

- $s_n(\alpha) = \sigma_R(P_n(\alpha))$

$$\begin{cases} \hat{\phi}_1 &= \underset{\|\alpha\|_\tau=1}{\operatorname{argmax}} \{s_n^2(\alpha) - \rho\Psi(\alpha)\} \\ \hat{\phi}_m &= \underset{\alpha \in \hat{\mathcal{B}}_{m,\tau}}{\operatorname{argmax}} \{s_n^2(\alpha) - \rho\Psi(\alpha)\} \quad 2 \leq m, \end{cases}$$

$$\hat{\mathcal{B}}_{m,\tau} = \{\alpha \in \mathcal{H} : \|\alpha\|_\tau = 1, \langle \alpha, \hat{\phi}_j \rangle_\tau = 0, \forall 1 \leq j \leq m-1\}.$$

- $\hat{\phi}_m \xrightarrow{\text{a.s.}} \phi_{R,m}$

BLDA: $X_i \in \mathcal{H} \ 1 \leq i \leq n$

- $\{\delta_i\}_{i \geq 1}$: base de \mathcal{H} . $p_n \uparrow \infty$

$$x_{ij} = \langle X_i, \delta_j \rangle$$

$$\mathbf{x}_i = (x_{i1}, \dots, x_{ip_n})^T$$

$$\|X_i - \hat{X}_i\|_{\mathcal{H}}^2 \simeq \|\mathbf{x}_i - \hat{\mathbf{x}}_i\|_{\mathbb{R}^p}^2$$

- Aplique un ajuste robusto a $\mathbf{x}_i = (x_{i1}, \dots, x_{ip_n})^T$, para obtener

$$\hat{\mathbf{x}}_i = \hat{\boldsymbol{\mu}} + \sum_{\ell=1}^q \hat{a}_{i\ell} \hat{\mathbf{b}}^{(\ell)}$$

- $\hat{\boldsymbol{\mu}} = (\hat{\mu}_1, \dots, \hat{\mu}_{p_n})^T$
- $\hat{\mathbf{b}}^{(\ell)} = (\hat{b}_{\ell 1}, \dots, \hat{b}_{\ell p_n})^T \in \mathbb{R}^{p_n}$, $\|\hat{\mathbf{b}}^{(\ell)}\| = 1$

BLDA: Aproximación en el espacio original \mathcal{H}

- $\hat{\mu} = \sum_{j=1}^{p_n} \hat{\mu}_j \delta_j$
- Base asociada de autofunciones estimadas en \mathcal{H} es

$$\hat{\phi}_\ell = \sum_{j=1}^{p_n} \hat{b}_{\ell j} \delta_j \quad 1 \leq \ell \leq q$$

- Los valores ajustados en \mathcal{H} son


$$\hat{X}_i = \hat{\mu} + \sum_{\ell=1}^q \hat{a}_{i\ell} \hat{\phi}_\ell$$

Datos de Ozono



- Mediciones horarios del nivel de concentración de Ozono (O_3 ppb)
- Agosto, 2004 a 2012, 176 días con mediciones horarias promedio
- Usamos un B -spline cúbico con 10 nodos, $q = 1$

Datos de Ozono - Residuos

S-residuals



LS residuos






Datos atípicos

Nivel Ozono: S -est. (Líneas continuas) y LS (Líneas punteadas)




2004

2006

2010



Temperatura and Lluvia: S -est. (●) y LS (▲)



Outliers identificados por el ajuste robusto corresponden a días con picos relativamente altos de concentración de O₃, pero algunos días tienen un perfil “llano”.

- El ajuste robusto identifica como atípicos los días con temperaturas o muy altas o muy bajas.
- Los días atípicos con perfil O3 “plano” corresponden a máxima temperatura baja.

Los días con un pico agudo de O3 peak corresponden a días calurosos.

- El método robusto identifica los outliers potenciales que corresponden a valores extremos de variables de una variable meteorológica claramente asociada.